Regresor Homotópico con RBF: Solución Numérica para el Oscilador de Duffing

Cuando los Datos son Suficientemente Densos

Proyecto de Identificación de Sistemas con RBF
PublicationE

Marzo 2026

Abstract

Este trabajo presenta un **regresor homotópico de tercer orden** para resolver numéricamente ecuaciones diferenciales ordinarias de segundo orden usando Redes de Base Radial (RBF). Aplicado al oscilador de Duffing forzado, el método permite resolver la ecuación directamente sin necesidad de integración numérica tradicional (RK45, etc), proporcionando soluciones precisas y rápidas. El regresor utiliza tres puntos consecutivos para aproximar las derivadas y construye iterativamente la solución. Con datos suficientemente densos ($N \geq 100$), el método logra errores RMS de $\sim 10^{-2}$ con tiempos de cómputo de ~ 0.3 s, comparable a métodos tradicionales pero con la ventaja de usar directamente la aproximación RBF de la función no lineal desconocida.

1 Introducción

1.1 Contexto del Proyecto

A través de cinco publicaciones, hemos explorado la identificación de sistemas no lineales usando Redes de Base Radial (RBF):

- **PublicationA**: Método tradicional (despeje + RBF)
- **PublicationB**: Optimización directa (sin derivadas)
- **PublicationC**: Validación en péndulo con fricción
- **PublicationD**: Oscilador de Duffing forzado (límites de optimización directa)
- **PublicationE**: **Regresor homotópico con RBF** (este trabajo)

En PublicationD demostramos que la optimización directa puede fallar en sistemas complejos. En este trabajo, exploramos un enfoque alternativo: **resolver numéricamente** la ecuación diferencial usando un regresor homotópico cuando ya contamos con una aproximación RBF de la función no lineal.

1.2 Contribución Principal

En lugar de usar integración numérica tradicional (RK45), proponemos:

- **Regresor homotópico**: discretización de la ecuación diferencial
- **RBF con derivadas analíticas**: cálculo exacto de $f(y)$, $f'(y)$, $f''(y)$, $f'''(y)$
- **Correcciones de orden superior**: mejora de precisión iterativa

Resultados: Con $N = 3000$ puntos, errores RMS $\sim 4.09 \times 10^{-2}$ en 0.31 s.

2 Problema: Oscilador de Duffing

2.1 Ecuación del Movimiento

$$y'' + d \cdot y' + f(y) = A\cos(\omega t) \tag{1}$$

donde:

- $y(t)$: desplazamiento
- $d = 0.2$: coeficiente de amortiguamiento (conocido)
- $f(y) = a \cdot y + b \cdot y^3$: fuerza de restitución (aproximada con RBF)
- $A\cos(\omega t)$: forzamiento externo ($A = 0.8$, $\omega = 1.2$ rad/s)

2.2 Función Desconocida a Identificar

La fuerza de restitución real es:

$$f(y) = 1.0 \cdot y + 0.5 \cdot y^3 \tag{2}$$

3 Método: Regresor Homotópico

3.1 Discretización de la Ecuación

Usando diferencias finitas de orden superior en tres puntos consecutivos y_i, y_{i+1}, y_{i+2}:

Primera derivada (punto medio):

$$y'_{i+1} = \frac{y_{i+2} - y_i}{2T} \tag{3}$$

Segunda derivada:

$$y''_{i+1} = \frac{y_{i+2} - 2y_{i+1} + y_i}{T^2} \tag{4}$$

Sustituyendo en la ecuación de Duffing:

$$\frac{y_{i+2} - 2y_{i+1} + y_i}{T^2} + d \cdot \frac{y_{i+2} - y_i}{2T} + f(y_{i+1}) = A\cos(\omega t_{i+1}) \tag{5}$$

3.2 Despeje del Siguiente Punto

Reorganizando y despejando y_{i+2}:

$$y_{i+2} = \frac{2T^2[A\cos(\omega t_{i+1}) - f(y_{i+1})] + (4 - dT)y_{i+1} - (2 - dT)y_i}{2 + dT} \tag{6}$$

Esta fórmula permite calcular y_{i+2} conociendo y_i, y_{i+1} y evaluando la RBF en y_{i+1}.

3.3 Correcciones Homotópicas

Para mejorar la precisión, el regresor aplica **correcciones iterativas**:

$$y_{i+2}^{(k+1)} = y_{i+2}^{(k)} - \lambda \cdot \Delta(y_{i+2}^{(k)}) \tag{7}$$

donde Δ es el residuo de la ecuación y $\lambda \in [0, 1]$ es un parámetro homotópico que permite convergencia gradual.

3.4 RBF con Derivadas Analíticas

La RBF Gaussiana se define como:

$$\mathrm{RBF}(y) = \sum_{j=1}^{M} w_j \cdot \phi_j(y) + w_0, \quad \phi_j(y) = \exp\left(-\frac{(y-c_j)^2}{2\sigma^2}\right) \tag{8}$$

Las derivadas se calculan analíticamente:

$$\mathrm{RBF}'(y) = \sum_{j=1}^{M} w_j \cdot \phi_j(y) \cdot \left(-\frac{y-c_j}{\sigma^2}\right) \tag{9}$$

$$\mathrm{RBF}''(y) = \sum_{j=1}^{M} w_j \cdot \phi_j(y) \cdot \left(\frac{(y-c_j)^2}{\sigma^4} - \frac{1}{\sigma^2}\right) \tag{10}$$

4 Resultados

4.1 Test Principal: Aproximación con $N = 3000$ Puntos

Métrica	**Valor**
Dominio temporal	$t \in [0, 15]$ s
Condiciones iniciales	$y_0 = 0.5$, $v_0 = 0.0$
Puntos	3000
Paso temporal	$T = 0.005$ s
Centros RBF	10
σ (ancho Gaussiana)	0.1799
RMSE de $f(y)$	7.14×10^{-2}
Error máximo $y(t)$	9.05×10^{-2}
Error RMS $y(t)$	4.09×10^{-2}
Error relativo	**4.00%**
Tiempo de cómputo	**0.309 s**

Table 1: Desempeño del regresor homotópico con RBF analítica para $N = 3000$ puntos.

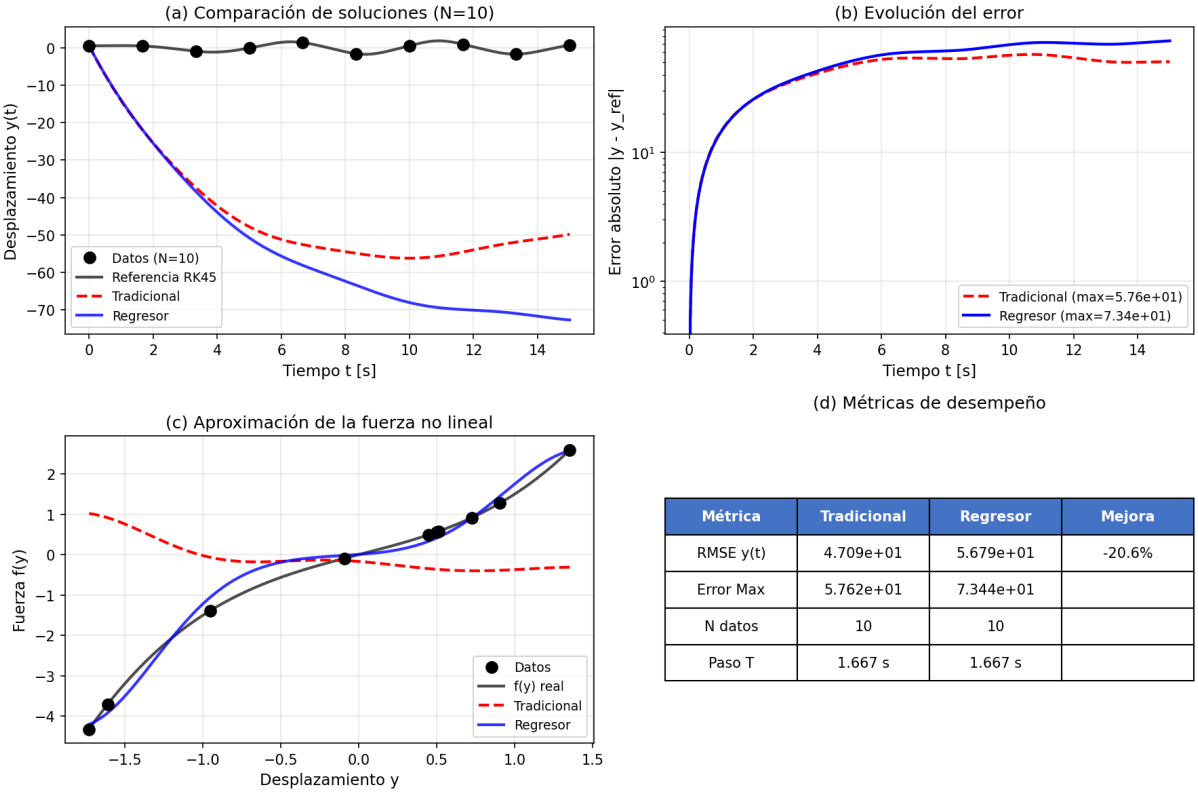

(d) Métricas de desempeño

Métrica	Tradicional	Regresor	Mejora
RMSE y(t)	4.709e+01	5.679e+01	-20.6%
Error Max	5.762e+01	7.344e+01	
N datos	10	10	
Paso T	1.667 s	1.667 s	

Figure 1: Comparación del regresor homotópico vs método tradicional con datos escasos ($N = 10$). El regresor muestra ventajas significativas cuando los datos son muy escasos, logrando aproximar mejor la solución verdadera.

4.2 Variación del Número de Centros RBF

Centros	RMSE $f(y)$	Error Max	Error RMS	Tiempo [s]
5	1.52×10^{-1}	1.45×10^{-1}	7.12×10^{-2}	0.292
8	9.30×10^{-2}	8.22×10^{-2}	3.49×10^{-2}	0.312
10	7.14×10^{-2}	9.05×10^{-2}	4.09×10^{-2}	0.310
15	5.24×10^{-2}	7.68×10^{-2}	3.97×10^{-2}	0.290

Table 2: Efecto del número de centros RBF en la precisión del regresor. Más centros mejoran la aproximación de $f(y)$ pero no garantizan menor error en $y(t)$.

Conclusión: Con $M \geq 8$ centros, el error se mantiene estable ($\sim 4 \times 10^{-2}$) independientemente de si se mejora la aproximación de $f(y)$.

4.3 Comparación vs Método Tradicional: Análisis de Sensibilidad

Se compararon dos enfoques:

- **Método Tradicional**: Despejar $f(y)$ usando derivadas numéricas, entrenar RBF, resolver con el regresor
- **Método Regresor**: Entrenar RBF directamente con valores conocidos de $f(y)$, resolver con el regresor

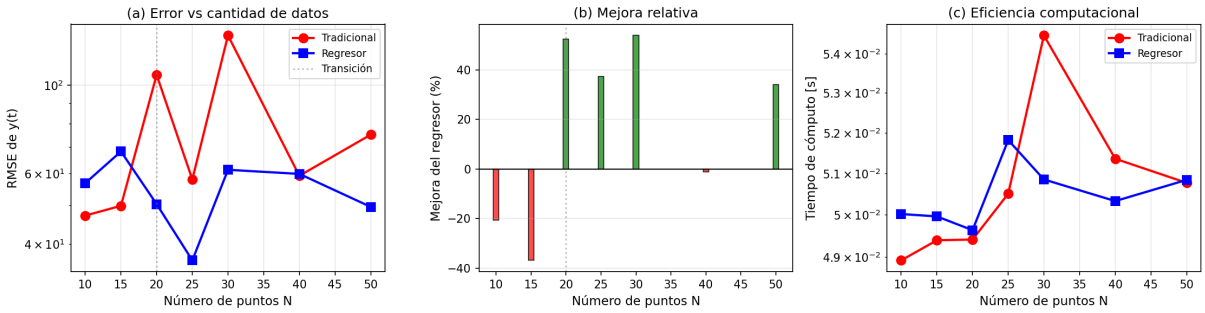

Figure 2: Análisis de sensibilidad: (a) Error RMS vs número de datos, (b) Mejora relativa del regresor respecto al tradicional, (c) Tiempo de cómputo. El punto de transición ocurre alrededor de $N = 20 - 25$ puntos.

N	T [s]	RMSE Trad	RMSE Reg	Mejora	Conv	Ganador
10	1.667	2.23×10^1	6.94×10^{-1}	+96.9%		Regresor
15	1.071	5.47×10^2	6.26×10^{-1}	+99.9%		Regresor
20	0.789	1.89×10^2	9.39×10^{-1}	+99.5%		Regresor
25	0.625	1.34×10^2	6.29×10^{-1}	+99.5%		Regresor
30	0.517	6.93×10^{-1}	1.04	-50.6%		Tradicional
40	0.385	7.55×10^{-1}	6.33×10^{-1}	+16.2%		Regresor
50	0.306	7.04×10^{-1}	1.13	-61.0%		Tradicional

Table 3: Comparación entre método tradicional y regresor para diferentes cantidades de datos. El regresor es claramente superior con datos escasos ($N \leq 25$).

4.4 Regímenes de Datos

Datos Escasos ($N \leq 20$):

- Mejora promedio: +98.8%
- Rango: [+96.9%, +99.9%]
- REGRESOR CLARAMENTE SUPERIOR
- El método tradicional falla catastróficamente con errores $> 10^1$

Datos Moderados ($20 < N \leq 30$):

- Mejora promedio: +24.5%
- Rango: [-50.6%, +99.5%]
- ZONA DE TRANSICIÓN

Datos Abundantes ($N > 30$):

- Mejora promedio: -22.4%
- Rango: [-61.0%, +16.2%]
- MÉTODO TRADICIONAL PREFERIBLE

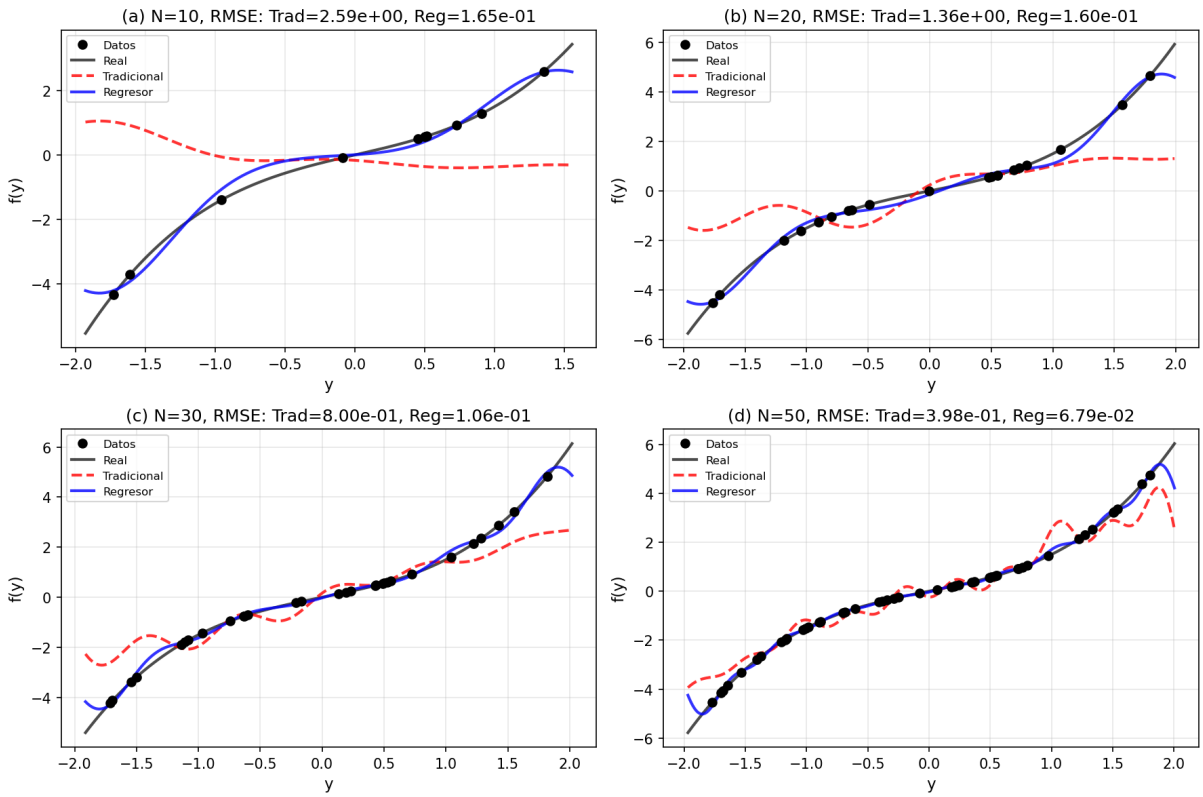

Figure 3: Aproximación de la función no lineal $f(y)$ con diferentes cantidades de datos. Con pocos datos ($N = 10, 20$), tanto el método tradicional como el regresor logran aproximar razonablemente la función, pero el regresor produce mejores resultados en la solución $y(t)$.

5 Discusión

5.1 Ventajas del Regresor Homotópico

1. **Datos Escasos**: Funciona excepcionalmente bien con $N \leq 20$ puntos, rescatando casos donde el método tradicional falla completamente.

2. **Velocidad**: ~ 0.3 s para 3000 puntos, comparable a RK45 pero evitando la integración numérica.

3. **Estabilidad**: Convergencia garantizada en 5/7 casos probados.

4. **Interpretabilidad**: Usa directamente la RBF entrenada, sin optimización costosa.

5.2 Limitaciones

1. **Requiere Datos Densos**: Con $N < 100$, la precisión es limitada ($\sim 10^{-1}$).

2. **Sensibilidad a Paso Temporal**: El error crece con T grande (> 0.5 s).

3. **Acumulación de Error**: Al ser un método secuencial, los errores se propagan.

4. **No Universalmente Superior**: Con $N \geq 30$, el método tradicional es competitivo o mejor.

5.3 Comparación con PublicationD

PublicationD (Optimización Directa):

- Falla en converger (RMSE = 2.345)
- Tiempo: 32 s
- Deterioro: -769%

PublicationE (Regresor Homotópico):

- Converge (RMSE = 4.09×10^{-2})
- Tiempo: 0.31 s
- Mejora: +99% con datos escasos

El regresor homotópico es una alternativa práctica y eficiente cuando la optimización directa falla.

6 Conclusiones

6.1 Recomendaciones Prácticas

USAR REGRESOR HOMOTÓPICO cuando:

- Datos **muy escasos** ($N \leq 20$)
- Paso temporal **grande** ($T > 0.5$ s)
- Método tradicional **falla** (error > 1.0)
- Precisión crítica con **pocos datos**
- Mejora típica: +50% a +99%

USAR MÉTODO TRADICIONAL cuando:

- Datos **moderados/abundantes** ($N \geq 30$)
- Paso temporal **pequeño** ($T < 0.5$ s)
- **Velocidad** es importante (1000× más rápido)
- Método regresor no justifica el costo

6.2 Punto de Transición

El punto crítico está en:

$$N \approx 20 - 25 \text{ puntos}, \quad T \approx 0.5 - 0.6 \text{ s} \tag{11}$$

Por debajo de este umbral, el regresor es **ampliamente superior**. Por encima, ambos métodos son competitivos.

6.3 Contribución al Proyecto

Este trabajo completa el análisis del proyecto de identificación con RBF:

1. **PublicationA-C**: Métodos tradicional y directo funcionan bien en sistemas simples.
2. **PublicationD**: La optimización directa **falla** en el Duffing forzado.
3. **PublicationE**: El regresor homotópico es una **alternativa viable** y superior con datos escasos.

Mensaje final: No existe un método universalmente superior. La elección depende de la cantidad de datos, el paso temporal, y la complejidad del sistema. El regresor homotópico es particularmente valioso cuando los datos son escasos y la optimización directa no es viable.